

Adaptive Forecast Weighting Data Fusion Algorithm for Wireless Sensor Network*

YU Xiuwu^{1 2*} FAN Feisheng¹ ZHOU Lixing^{1 2} ZHANG Feng^{1 2}

(1. Environmental Protection and Safety Engineering Institute, University of South China, Hengyang, Hunan 421001, China;

2. The State Key Laboratory of Safety and Health for Metal Mines, Maanshan, Anhui 243000, China)

Abstract: In order to improve the reliability and extend lifetime of wireless sensor network (WSN) monitoring system, an adaptive forecast weighting data fusion (AFWDF) algorithm based on clustering is proposed. AFWDF builds a forecast model based on the temporal correlation of data. The source node and the cluster head adaptively adjust the prediction model parameters by using the change trend of the early monitoring data to predict the later data. The source node extracts the eigenvalues and eliminates the abnormal values by comparing the predicted values with the measured values. The cluster head restores the monitored values and calculates the reliability and weight of the monitored values to fuse them. Through the performance analysis and simulation, it is concluded that the AFWDF algorithm has high reliability, and the network life cycle is about 15% higher than SAEMDA and BPNDA in the simulation environment.

Key words: wireless sensor network; data fusion; adaptive forecast model; environmental monitoring; reliability

EEACC: 7230

doi: 10.3969/j.issn.1004-1699.2017.05.023

无线传感器网络自适应预测加权数据融合算法*

余修武^{1 2*} 范飞生¹ 周利兴^{1 2} 张 枫^{1 2}

(1. 南华大学环境保护与安全工程学院, 湖南 衡阳 421001; 2. 金属矿山安全与健康国家重点实验室, 安徽 马鞍山 243000)

摘要: 为提高无线传感器网络监测系统的可靠性及寿命, 提出了一种基于分簇的自适应的预测加权数据融合 (AFWDF) 算法。AFWDF 算法依据数据在时间上的相关性, 建立预测模型。源节点与簇头利用前期监测数据的变化态势自适应调整预测模型参数对后期数据进行预测。源节点通过预测值与测量值比较提取特征值和剔除异常值, 簇头根据特征值和预测值还原监测值, 并计算监测值可信度和权重进行加权数据融合。通过性能分析及仿真, 得出 AFWDF 可靠性较高, 且在模拟环境下网络寿命周期比 SAEMDA 和 BPNDA 算法提高了 15% 左右。

关键词: 无线传感器网络; 数据融合; 自适应预测模型; 环境监测; 可信度

中图分类号: TP393

文献标识码: A

文章编号: 1004-1699(2017)05-0772-05

无线传感网络 WSN (Wireless Sensor Network) 由大量的无线传感器节点及少数汇聚节点组成, 具有感知、计算和无线通信能力, 可用于各种环境监测领域^[1-2], 能够实时动态的进行数据采集分析, 有效的对环境参数进行监测预警。由于传感器节点一般随机布设, 且单个节点监测范围受限, 为增加监测数据的鲁棒性和可靠性, 要使多个节点监测范围部分重叠, 这势必造成了监测数据的冗余^[3], 而 WSN 能量、存储、通信带宽等资源非常有限^[4-5], 为保证 WSN 能够长期有效运行, 必须尽量降低其运行能

耗。且传感器属于灵敏元件, 在外界环境的干扰下很容易得到不可靠数据。为了增加可靠性和通信效率、降低能耗来提高节点以及整个网络寿命, 需对数据进行融合处理。

如何增加数据可靠性及延长网络寿命是 WSN 中的一个关键问题^[6-10], 文献 [8] 提出使用信息熵反映节点数据分布的统计特性, 最大寻优确定数据融合上下限阈值进行局部融合、实现冗余数据过滤, 但其融合率低, 融合度受到熵值的限制, 节能有限; 文献 [9] 从驱动事件出发, 使用 BP 神经网络 (BPNDA) 对数据

项目来源: 金属矿山安全与健康国家重点实验室开放基金项目 (2016JSKSSYS04); 湖南省重点研发项目 (2015SK2005); 湖南省教育厅科研重点项目 (15A161); 江西省自然科学基金项目 (20122BAB201050)

收稿日期: 2016-09-08 修改日期: 2017-01-11

融合动态训练样本信息, 提取特征值, 但该算法在不合标签信息时将无法训练, 且事件驱动训练成本较高; 文献[10]基于深度学习模型(SAEMDA)采用自动编码器簇内构建特征提取分类模型, 克服了传统训练方法的不足, 一定程度上减少了数据转发能耗。以上算法对数据的可靠性分析较少, 单纯的以数据为中心融合, 容易产生不可靠融合数据, 且目前由于能耗的限制, WSN 生命周期还较短, 为最大限度延长网络生命周期及提高数据可靠性, 本文使用自适应预测模型在源节点即提取数据特征值来判断数据可靠性, 并发送可靠数据特征值至融合簇头, 簇头还原原始数据并以数据可信度进行加权融合, 在保证数据的可靠性的基础上大大降低了通信能耗。

1 自适应预测模型

监测节点布设完成后, 通过分簇机制自行分簇, 选取簇头节点, 在此采用经典的 LEACH^[11] 分簇模型。假设源(S)节点通过定位 ID 位置已知, 初始状态 S 节点数据集为空, 当监控中心给 S 节点下达监测指令, 开始收集数据。若簇内有 n 个 S 节点, 设为 S_i (i 为 $1, 2, 3, \dots, n$), S_i 监测时间序列数据集为 $\{d_{ij}\}$ (j 为时间序列 (j 为 $1, 2, 3, \dots$))。在 WSN 中节点采集的数据之间在时间上存在着相关性, 即后一时刻的数据和前期的监测数据有关, 且时间越接近相关性越大, 故可通过前期数据来预测后一时刻数据, 建立时间预测模型, 通过预测值与测量值求取特征值与可信度来加权融合监测数据。

预测及融合流程如图 1 所示。

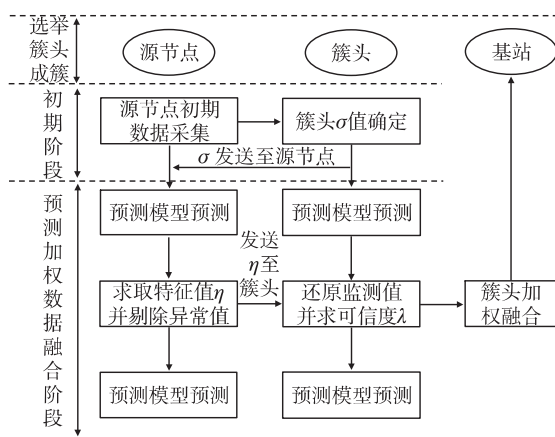


图 1 AFDWF 数据融合流程

1.1 预测模型的建立

WSN 的监测是一个实时在线过程, 数据之间存在一定的连贯性。如果在无强烈的外力的干扰下, 如人为干扰产生异常值或者环境突变而发生的监测数据急剧增加或降低, 相邻的监测数据不会产生剧

烈的变化。结合预测模型理论, 可用如下平滑预测模型进行预测, 如式(1)所示^[12]:

$$d_{i(j+T)}^* = a_{ij} + b_{ij}T \quad T=1, 2, \dots \quad (1)$$

式中: T 取 1, 即进行下一时期预测; a_{ij} , b_{ij} 为平滑系数, 且 $a_{ij} = 2E_{ij}^{(1)} - E_{ij}^{(2)}$, $b_{ij} = \frac{\alpha_{ij}}{1-\alpha_{ij}}(E_{ij}^{(1)} - E_{ij}^{(2)})$ 。

$E_{ij}^{(1)}$ 为 j 时期一次指数平滑值, $E_{ij}^{(2)}$ 为 j 时期二次指数平滑值, 它们的递推公式分别如式(2)、式(3)。 α_{ij} 为数据的线性变化趋势 ($0 \leq \alpha_{ij} \leq 1$) $\alpha_{ij} \rightarrow 1$ 趋势越大。

$$E_{ij}^{(1)} = \alpha_{ij}d_{ij} + (1-\alpha_{ij})E_{i(j-1)}^{(1)} \quad (2)$$

$$E_{ij}^{(2)} = \alpha_{ij}E_{ij}^{(1)} + (1-\alpha_{ij})E_{i(j-1)}^{(2)} \quad (3)$$

$E_{i0}^{(1)}$, $E_{i0}^{(2)}$ 取第 1 个时期的动态数据均值, 即 $E_{i0}^{(1)} = E_{i0}^{(2)} = d_{i1}$ 。

外界环境的变化会使数据拥有不同的变化趋势, 为增加预测的准确性, α_{ij} 需进行自适应调整。

1.2 异常值检测机制

节点监测是建立在数据可靠性的基础之上的, 然而由于存在节点受外界局部因素的扰动, 监测数据可能会产生异常值, 故需要进行异常值检测。在同一时期众多节点在同一区域分别采集数据, 数据之间符合正态分布的关系, 即 $N(\mu, \sigma^2)$, 根据高斯分布特性, 当横轴区间在 $(\mu - 2.58\sigma, \mu + 2.58\sigma)$ 内, 其数据比例为 99%, 为大概率事件, 超出此区间范围概率为 1% 为小概率事件, 故可以认为在 $(\mu - 2.58\sigma, \mu + 2.58\sigma)$ 范围之外的数据为异常值。其中 $\mu = \bar{d}_{ij} =$

$$\frac{1}{n} \sum_{i=1}^n d_{ij} \quad \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (d_{ij} - \bar{d}_{ij})^2}$$

且外界环境变化时 $\sigma^+ = \sqrt{\frac{1}{n} \sum_{i=1}^n [(d_{ij} + \delta d) - (\bar{d}_{ij} + \delta \bar{d})]^2} = \sigma$, 即 σ 值不随监测数据的变化而变化, 故 σ 值可由簇头节点通过对初始采集数据进行计算确定, 即 $\sigma =$

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (d_{i1} - \bar{d}_{i1})^2}$$

簇头记忆并发送给各个节点, 各节点保存作为计算参数, 之后不需重复计算。

由于监测数据之间具有相关性, 且相邻两监测数据之间差距较小, 预测值趋近于前期数据, 可以认为预测值趋近于真实值, 当测量值和预测值发生较大误差时, 则用如下机制确定。

$$\begin{cases} |\eta_{ij} = d_{ij}^* - d_{ij}| \geq 2.58\sigma & \text{采集数据为异常值} \\ |\eta_{ij} = d_{ij}^* - d_{ij}| < 2.58\sigma & \text{采集数据为可信值} \end{cases}$$

式中: d_{ij}^* 为预测值, d_{ij} 为测量值, η_{ij} 为特征值。

1.3 自适应线性变化趋势系数 α_{ij}

设初始状态 $\alpha_{ij} = 0$, 即 $d_{i2}^* = d_{i1}$, 设有 j 时期数据线性变化趋势系数 $\alpha_{ij}^* = \eta_{ij} / 2.58\sigma$, 当 $j > 1$ 时, 为描述数

据趋势变化态势,可令 $\alpha_{i(j+1)} = \alpha_0 \alpha_{i(j+1)}^* + (1 - \alpha_0) \alpha_{ij}$, $\alpha_{i(j+1)}$ 与 $j+1$ 时期数据趋势系数 $\alpha_{i(j+1)}^*$ 及 j 时期自适应线性变化趋势系数 α_{ij} 有关,呈动态变化, α_0 表示预测平滑系数,反应前期变化趋势在时间上的衰减, α_0 越大数据在时间上的衰减越快,可取 $\alpha_0 = 2/(N+1)$, N 为时间周期,在此 N 取 4。

2 自适应预测加权数据融合算法

自适应预测加权数据融合算法 AFDWF (Adaptive Forecast Weighting Date Fusion) 是在自适应预测模型的基础上,通过预测值与监测值的比较,提取特征值,特征值数据比源监测数据小的多,根据特征值排除异常值,并可得出监测值的可信度,进而根据可信度算出权重,依据权重最终对监测数据进行融合的一种算法。

2.1 监测数据可信度

源节点在 j 时期采集一组数据,发送给簇头,并预测 $j+1$ 时期的数据,即 $d_{i(j+1)}^*$,同时簇头通过源节点采集的数据运用预测模型对各个节点 $j+1$ 进行预测,也为 $d_{i(j+1)}^*$ 。此后 $j+1$ 时期源节点进行数据采集,通过预测值和监测值提取特征值 $\eta_{i(j+1)}$,数据为异常值不发送,数据为可信值则发送特征值 $\eta_{i(j+1)}$ 至簇头。 $\eta_{i(j+1)}$ 值不同代表监测值可信度 $\lambda_{i(j+1)}$ 不同,可信度 $\lambda_{i(j+1)}$ ($0 \leq \lambda_{ij} \leq 1$) 可用式(4)表示。即偏离预测值越远,可信度越低,偏离预测值越近,可信度越高。

$$\lambda_{i(j+1)} = (2.58\sigma - |\eta_{i(j+1)}|) / (2.58\sigma) \quad (4)$$

化简得

$$\lambda_{i(j+1)} = 1 - |\eta_{i(j+1)}| / (2.58\sigma) \quad (5)$$

2.2 加权融合

簇头接收各节点的特征值 $\eta_{i(j+1)}$,则可求出监测值 $d_{i(j+1)} = \eta_{i(j+1)} + d_{i(j+1)}^*$,存储作为下一次预测原始数据,可大大减少簇内传输的数据包。为了进一步压缩数据,使簇头发送的数据包最小化,使用加权求和。

其中权重 q 计算公式如下

$$q = \lambda_{i(j+1)} / \sum_{i=1}^n \lambda_{i(j+1)}$$

则最终融合值 d_{j+1} 如式(6)所示。

$$d_{j+1} = \sum_{i=1}^n q d_{i(j+1)} \quad (6)$$

3 算法性能分析及仿真

3.1 可靠性分析

3.1.1 预测模型分析

本实验采用美国 Inspector ALERT V2 多功能辐射测氡仪采集了两组某铀尾矿库内两个不同时间段

的同一区域各节点连续时期 γ 射线辐射剂量率(单位 $\mu\text{Sv/hr}$) 样本数据,分别设为节点 S_1 、 S_2 时间段,在此把同一时期的各节点样本数据做均值处理,分别使用上述平滑预测模型进行预测,即

$$d_{i(j+T)}^* = \left(2 + \frac{a_{ij}}{1-a_{ij}}\right) E_{ij}^{(1)} - \left(1 + \frac{a_{ij}}{1-a_{ij}}\right) \times [a_{ij} E_{ij}^{(1)} + (1-a_{ij}) E_{i(j-1)}^{(2)}]$$

式中: $E_{ij}^{(1)}$ 、 $E_{i(j-1)}^{(2)}$ 可根据式(2)、式(3)求得, α_{ij} 为自适应线性变化趋势系数, $\alpha_{i(j+1)} = \alpha_0 (\eta_{i(j+1)} / 2.58\sigma) + (1 - \alpha_0) \alpha_{ij}$, σ 值由各节点前期测量值确定,且平均测量与预测值为同一时间点同一区域的测量与预测数据的均值。

图2为此两时间段测量与预测均值比较。

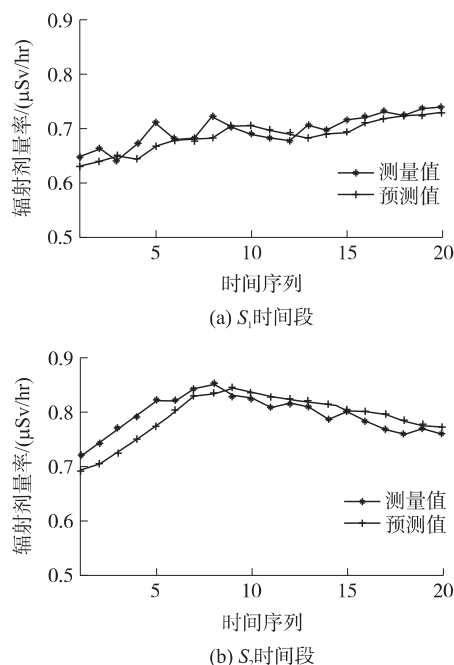


图2 S_1 、 S_2 时间段节点平均测量值与预测值

选取实验样本测得 $2.58\sigma = 0.075$,测量值与预测值在 S_1 时间段有最大相对误差 ε_{\max}

$$\varepsilon_{\max} = |(d_{i6}^* - d_{i6}) / d_{i6}| \times 100\% = (0.710 - 0.667) \times 100\% = 0.043 \times 100\% = 6.06\%$$

两组实验测量值与预测值平均相对误差为

$$\bar{\varepsilon} = \left[\left(\sum_{j=2}^{21} \varepsilon_{ij}^{S1} + \sum_{j=2}^{21} \varepsilon_{ij}^{S2} \right) / 40 \right] \times 100\% = 2.37\%$$

计算所得 ε_{\max} 和 $\bar{\varepsilon}$ 都小于 0.1,且由图2可以看出预测值和测量值相差不大,在可接受范围之内,使用该预测模型能够较好的反应监测数据的变化规律。

3.1.2 AFDWF 可靠性分析

假设节点 i 一次测量值和预测值属于独立事件,分别称为事件 A 和 B ,事件成功率分别为 p_{i1} 和 p_{i2} ,由于预测模型存在异常值检测机制,当 A 、 B 都成功时直

接判断为可信值, 当 A 、 B 只有一个成功发生时, 直接判断为异常值, 当都不成功时存在两种情况: 被检测为异常值, 即两失败事件特征值 $\eta_{ij} > 2.58\sigma$; 检测为可信值 $\eta_{ij} \leq 2.58\sigma$ 。两失败事件可看成是两个随机生成数, 其检测为可信值概率很小, 设为 p_x , 相应的异常值概率为 p_y , $p_x + p_y = 1$, 且 $p_y \gg p_x$, 则节点 i 一次预测、测量失败事件在检测机制判断为可信值后仍然不可靠概率 (可简称为可信不可靠概率) 为 $p^* = (1 - p_{i1}) \times (1 - p_{i2}) p_y$, 可信不可靠概率直接影响到 FWDF 算法的可靠性, 当簇内有一个节点判断失误, 则增加融合数据误差。则只有当簇内 n 个节点都不存在可信不可靠数据时融合误差才会很小, 设其概率为 p , 则

$$p = \prod_{i=1}^n [1 - (1 - p_{i1})(1 - p_{i2})p_y]$$

若令 A 、 B 事件成功率 $p_{i1} = p_{i2} = 0.9$, $p_x = 0.1$, n 为 6, 则 $p = 0.994$, 即可信可靠数据率为 0.994, 可靠性能较高。

3.2 算法能耗分析

数据融合算法的优良除了需考虑数据可靠性外, 另外一个最重要的因素是系统和节点的网络寿命, 节点的能量消耗主要分为两个部分, 信号收发 (通信) 和信号处理, 研究表明^[13] 通信能耗远远大于信号处理能耗, 故减少收发数据包的大小能够有效的减少节点的能量消耗, 节点能量消耗 (E_{con}) 模型可用式 (7) 表示。

$$E_{con} = k_1 E_{rec} + k_2 E_{send} (d \varepsilon_{mp}) + k_3 E_{trans} + E_{collect} \quad (7)$$

式中: k_1 、 k_2 和 k_3 分别为节点接收、发送和处理数据包的大小, E_{rec} 和 E_{send} 分别为节点接收、发送和处理 1 bit 的数据包消耗的能量 (在环境一定的情况下为定值), 其中 E_{send} 和发送距离 d 和多径衰落系数 ε_{mp} 有关, 且 $E_{trans} \ll E_{send}$ 与 E_{rec} , $E_{collect}$ 为节点数据采集能耗 (指定能耗, 在此假设为一固定值)。

AFWDF 算法运用 LEACH 协议对网络节点进行分簇。若网络数据未融合, 即源节点数据包直接经过簇头发送给汇聚节点, 设每个节点数据包大小相同且都为 k , 则一个簇其除去数据采集所需能耗之外的网络能耗为 $E_1 = nk(2E_{send} + E_{rec} + E_{trans})$ 。通过 AFWDF 算法融合之后, 其网络能耗为 $E_2 = nk[(\rho_1 + \rho_2)E_{send} + \rho_1 E_{rec}] + \rho_3 nk E_{trans}$, 其中 n 为簇内源节点数量, ρ_1 为特征值提取数据包压缩系数 ($0 < \rho_1 < 1$), 如表 3 所示, 特征值的数据远远小于源采集数据, 即 $0 < \rho_1 \ll 1$; ρ_2 为簇头数据包压缩系数 ($0 < \rho_2 < 1$), 且 $\rho_2 \approx 1/n$; ρ_3 为数据处理倍增系数。

假设 $E_{rec} = (3/4)E_{send}$, $E_{trans} = (1/1000)E_{send}$, $\rho_1 = 0.1$, $\rho_2 = 0.1$, $\rho_3 = 10$ 。则 $E_2 \approx 0.1E_1$, 融合后节点能耗显著降低。

3.3 网络仿真对比

为了更好的分析 AFWDF 算法的性能, 在此通过仿真对 AFWDF 算法与 BPND 算法和 SAEMDA 算法的网络消耗和寿命进行简化比较。为了保持仿真环境的近似性, 采用同种通信能耗模型和 LEACH 分簇协议, 设置在 $100 \text{ m} \times 100 \text{ m}$ 平面区域中, 设置初始化参数如表 1 所示, 布设 50 个节点。在此使用简化能耗模型, 即不考虑通信距离、通信多径衰落、等因素的影响, 直接以定值 E_{rec} 、 E_{trans} 、 E_{send} 和数据包长度来模拟 20 s 计算一次网络能耗。

表 1 仿真参数设置

初始化参数	参数值	初始化参数	参数值
源节点初始能量	1 J	截取能耗时间	200 s
数据包长度	200 byte	E_{rec}	30 nJ/bit
包头长度	20 byte	E_{trans}	5 pJ/bit
分簇包长度	20 byte	E_{send}	40 nJ/bit

由图 3 可以看出, 在 600 轮之前 AFWDF 的汇聚节点收包率稍低于 SAEMDA 和 BPND, 600 轮之后 SAEMDA 和 BPND 下降趋势明显, 至 700 轮左右下降至低于 AFWDF, 1100 轮左右收包率趋于零, 而 AFWDF 下降趋势相对于 SAEMDA 和 BPND 较慢, 寿命相对增加 15% 左右。这是因为: AFWDF 是由簇头高度融合的数据, 其相对于其余两种算法的数据融合率较高, 且能够剔除异常数据, 相应的减少了信息通信量, 网络能耗低; 3 种算法工作一段时间后出现死亡节点或无效节点, 使汇聚节点接收数据量减少, 降低了收包率。




图 3 汇聚节点收包率与实验轮数的关系

算法平均节点能量对比如图 4 所示, 在相同的实验时间下, AFWDF 明显比 SAEMDA 和 BPND 平均节点能量多, 而 SAEMDA 与 BPND 差距不大。




图 4 平均节点能量与实验时间的关系

与 SAEMDA 和 BPND 算法相比,AFWDF 算法相对简单,利用预测减少了数据样本训练的损耗,降低了传输至簇头数据包的大小,同时在簇头的加权高度融合下,进一步降低了通信量,即明显降低了平摊到单节点的能耗。

4 结束语

AFWDF 算法依据数据在时间上的相关性,提出在源节点及簇头同时使用自适应型预测模型进行预测分析,利用监测数据的变化态势动态调整预测模型的参数,源节点通过对预测值和测量值的比较提取特征值并排除异常值,簇头求取监测值可信度及权重对监测数据进行融合。AFWDF 算法属于高度融合型算法,信息提取度较高,降低了数据传输能耗,能够有效的延长网络的整体寿命。同时,由于预测模型监测数据需建立在相近时间段的条件下,AFWDF 只适用于动态实时在线监测系统。对于数据监测间隔时间较长,时间相关性很小的监测系统,预测模型有待进一步研究。

参考文献:

- [1] Md Azharuddin, Prasanta K Jana. A Distributed Algorithm for Energy Efficient and Fault Tolerant Routing in Wireless Sensor Networks[J]. Wireless Networks, 2015, 21(1): 251-267.
- [2] 余修武, 范飞生, 李睿, 等. 基于接受信号强度分区矿山无线定位算法[J]. 中国安全生产科学技术, 2015, 11(9): 70-75.
- [3] Azlan Awang, Shobhit Agarwal. Data Aggregation Using Dynamic Selection of Aggregation Points Based on RSSI for Wireless Sensor Networks[J]. Wireless Personal Communications, 2015, 80(2): 611-633.
- [4] Arafat A A Shabaneh, Azizi Mohd Ali, Chee Kyun Ng et al. Review of Energy Conservation Using Duty Cycling Schemes for IEEE 802.15.4 Wireless Sensor Network (WSN) [J]. Wireless Personal Communications, 2014, 77(1): 589-604.
- [5] Azlan Awang, Shobhit Agarwal. Data Aggregation Using Dynamic Selection of Aggregation Points Based on RSSI for Wireless Sensor Networks[J]. Wireless Personal Communications, 2015, 80(2): 611-633.
- [6] Tarek Sheltami. An Enhanced Energy Saving Approach for WSNs [J]. Procedia Computer Science, 2013, 21: 199-206.
- [7] Pinghui Zou, Yun Lin. A Data-Aggregation Scheme for WSN Based on Optimal Weight Allocation[J]. Journal of Networks, 2014, 9(1): 100-107.
- [8] 李怀俊, 张学习. 基于二维信息熵的无线传感器网络簇内数据融合方法的研究[J]. 计算机应用研究, 2014, 31(7): 2171-2174.
- [9] 侯鑫, 张东文, 钟鸣. 基于事件驱动和神经网络的无线传感器网络数据融合算法研究[J]. 传感器技术学报, 2014, 27(1): 142-148.
- [10] 邱丽达, 刘天健, 林南, 等. 基于深度学习模型的无线传感器网络数据融合算法[J]. 传感技术学报, 2014, 27(12): 1704-1709.
- [11] Lee S, Sriram K, Kim K et al. Vertical Hand off Decision Algorithms for Providing Optimized Performance in Heterogeneous Wireless Networks[J]. IEEE Trans on Vehicular Technology, 2009, 58(2): 865-881.
- [12] 鲁庆, 穆志纯. 多层线性模型在碳钢土壤腐蚀规律中的应用研究[J]. 北京科技大学学报, 2013, 35(11): 1458-1464.
- [13] Min R, Bhardwaj M, Seonghwan Cho et al. Energy-Centric Enabling Technologies for Wireless Sensor Networks [J]. IEEE Wireless Communications, 2002, 9(4): 28-29.



余修武(1976-) 男, 江西九江人, 博士, 副教授, 主要研究方向为安全智能监测预警技术, 安全科学技术, 1248575964@qq.com;



范飞生(1990-) 男, 江西上饶人, 硕士研究生, 主要研究方向为无线传感器网络数据处理, 1098471222@qq.com;



周利兴(1993-) 男, 山西朔州人, 硕士研究生, 主要研究方向为无线定位技术;



张枫(1993-) 女, 湖南邵阳人, 硕士研究生, 主要研究方向为, 无线传感器数据融合技术。